Tema 4

El Nivel Interno

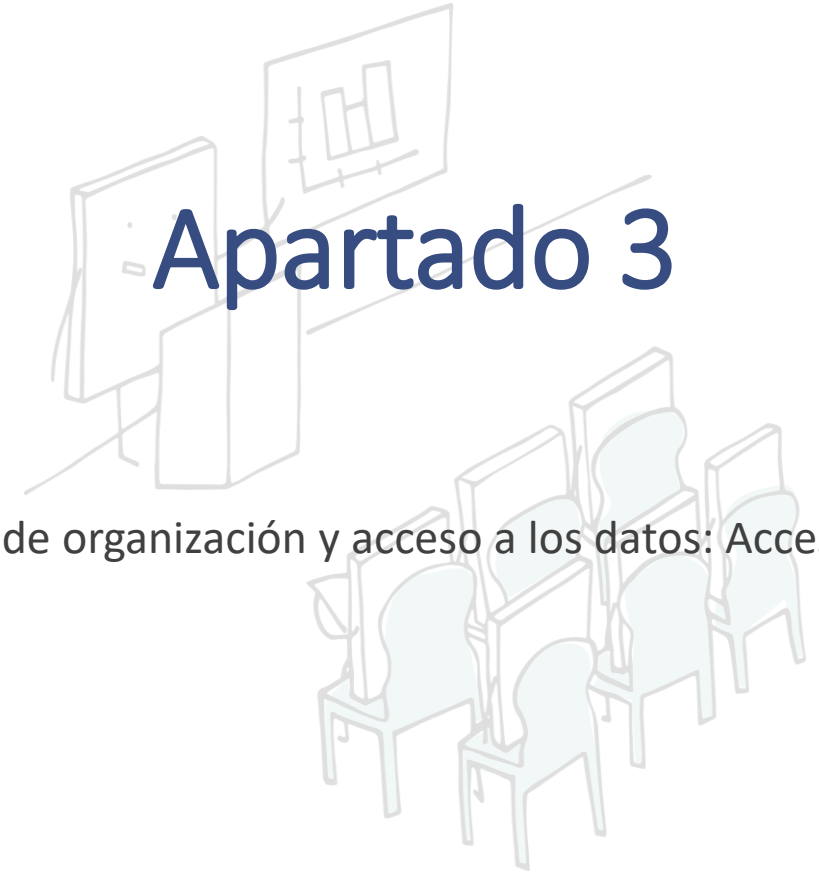

Apartado 3

Métodos de organización y acceso a los datos: Acceso Directo

Contenidos

- Acceso directo
- Hashing básico
- Hashing dinámico

Contenidos

- Acceso directo
- Hashing básico
- Hashing dinámico

Acceso directo

- Otra forma de acceder a un registro almacenado
  - No hay una estructura adicional
  - Se usa un algoritmo que nos indique directamente la posición del registro deseado.

- Acceso directo:
  - Calcular directamente la dirección de un registro mediante la aplicación de algún algoritmo o función sobre un campo determinado del mismo.
    - El campo debe identificar unívocamente al registro

Acceso directo

- Funcionamiento:
  - Normalmente no es posible establecer una clave física que sea totalmente correlativa y única para cada registro.
  - Hay que buscar un algoritmo que transforme los valores de un cierto campo en una dirección.
    - Entrada: campo clave
    - Salida: valor entero positivo fácilmente transformable en RID.

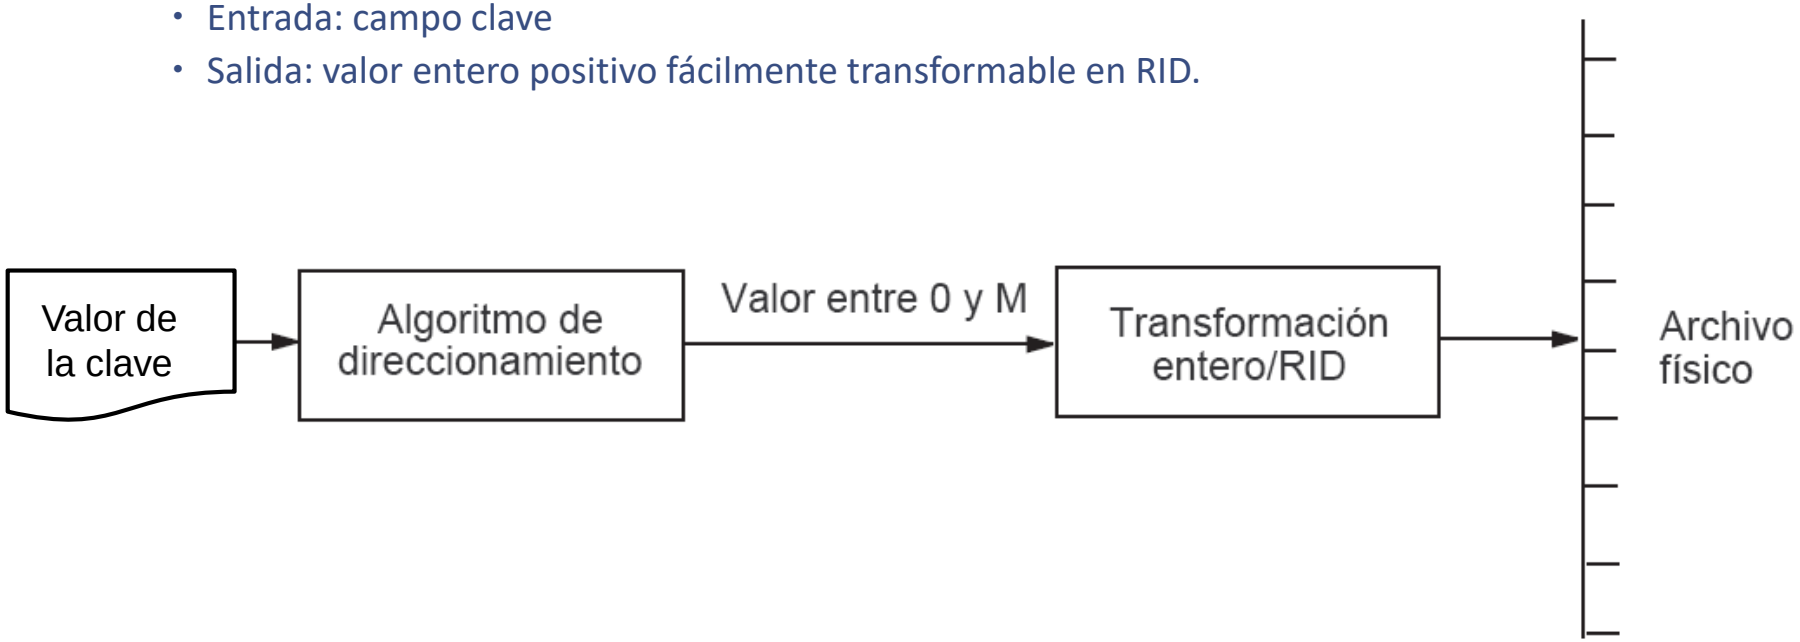

Acceso directo

- Los algoritmos de direccionamiento no suelen mantener el orden de la clave.
  - Los registros no están almacenados según el orden de su clave física.
  - Problemas con la recuperación por intervalos.

Acceso directo

- Hay una gran variedad de algoritmos:
  - Dependen del tipo de clave:
    - Si la clave es alfanumérica, hay que transformarla a un valor numérico.
  - Suelen estar basados en un mecanismo de generación de números pseudoaleatorios:
    - *Cuadrados centrales:*
      - Se eleva la clave al cuadrado y se eligen tantos dígitos centrales como sea necesario.
    - *Congruencias:*
      - Se divide la clave por M y se toma el resto. (M suele ser primo).
    - *Desplazamiento:*
      - Se superponen adecuadamente los dígitos binarios de la clave y luego se suman.
    - *Conversión de base:*
      - Se cambia la base de numeración y se suprimen algunos dígitos resultantes.

Acceso directo

- Problemas
  - Salvo que el campo clave se diseñe para ello, es prácticamente imposible encontrar una transformación que dé un valor entero positivo en un rango de valores limitado tal que:
    - No haya dos valores distintos de clave que den lugar al mismo número.
      - Colisiones.
  - Los algoritmos producen huecos:
    - Zonas vacías del rango de salida, no asignadas por el algoritmo.
    - Se traducen en huecos en el fichero de datos.

Acceso directo

- Para gestionar colisiones y huecos:
  - Combinar el acceso directo con una gestión mediante listas de colisión:
    - Zona de desbordamiento
    - Colisión:
      - El registro problemático se almacena en la zona de desbordamiento.
      - Los sinónimos (registros con claves que producen colisión) se conectan mediante una lista.

Acceso directo

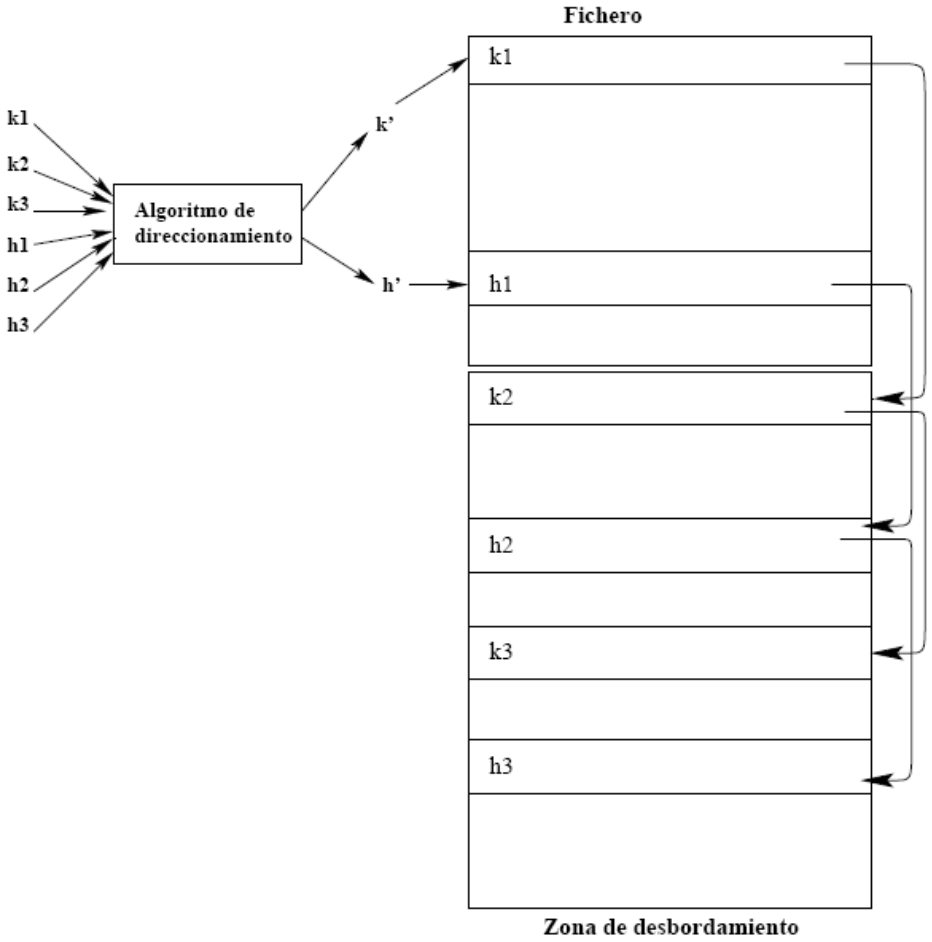

Acceso directo

- Si crecen las listas de sinónimos:
  - El acceso directo puro no resulta adecuado.
    - Mantener listas.
    - Zona de desbordamiento casi como el fichero original.

- Han aparecido técnicas más sofisticadas:
  - Hashing

Contenidos

- Acceso directo
- Hashing básico
- Hashing dinámico

Hashing básico

- Si el problema principal es que los valores de las claves no están uniformemente distribuidos en el intervalo [0,M]:
  - Se acumulan en una parte de este intervalo.
  - Solución:
    - Asignar más espacio a esa parte del intervalo.

- Técnica:
  - Se divide el espacio del fichero en “cubos” (buckets).
  - El algoritmo de direccionamiento asigna cubos, no direcciones concretas.
  - En cada “cubo” puede haber más de un registro.
  - Ciertos rangos de valores pueden tener asignados más cubos que otros.
  - Se complementa con el uso de “cubos de desbordamiento”.

Hashing básico

- Parámetros:
  - Número de cubos.
  - Tamaño de los cubos (relación con bloques físicos)
    - "slots"
  - La transformación clave/dirección, que debe tener en cuenta la distribución de la clave según rangos para evitar que unos cubos no se llenen mucho y otros se queden muy vacíos.

Hashing básico

- Para insertar un registro:
  - Transformar la clave.
  - Localizar el cubo correspondiente.
  - Si hay sitio se inserta el registro y hemos terminado.
  - Si no hay sitio, se sitúa el registro en un cubo de desbordamiento conectándolo con el cubo que realmente le corresponde mediante punteros.

Hashing básico

- El proceso de búsqueda:
  - Transformar la clave.
  - Localizar el cubo correspondiente.
  - Realizar una búsqueda secuencial dentro del cubo.
    - Si hemos encontrado el registro, el proceso termina.
    - En caso contrario, se impone “un barrido por punteros” a través de los cubos de desbordamiento.

Contenidos

- Acceso directo
- Hashing básico
- Hashing dinámico

Hashing dinámico

- El hashing básico sigue teniendo problemas:
  - Es necesario conocer la distribución previa de las claves para asignar adecuadamente los cubos.
    - En otro caso siguen apareciendo huecos/colisiones.
    - Al aumentar el número de registros, aumentan los registros en páginas de desbordamiento.
    - Se hacen necesarias las reorganizaciones.

Hashing dinámico

- Solución:
  - Trabajar de forma dinámica
- Se parte de una configuración uniforme y de pocos cubos
- Los restantes, se van generando conforme se necesiten.
  - Se asignan a los rangos conforme la afluencia de registros lo demanda.
  - Hashing dinámico o extensible

Hashing dinámico

- Técnica:
  - El valor transformado del campo clave nos lleva a la entrada de una tabla índice que se almacena en memoria.
  - Allí está la dirección del cubo donde se encuentran los registros que tienen asociado este valor transformado.
  - Puede ocurrir que varias entradas de la tabla conduzcan al mismo cubo.
  - Proceso:
    - Hay una asignación inicial de entradas a cubos, inicialmente pocos. Por ejemplo, todas las entradas apuntando al mismo cubo.
    - A medida que vamos insertando registros, se van generando nuevos cubos y cambiando las salidas de la tabla índice.

Hashing dinámico

- Algoritmo de Hashing Dinámico
  - Datos de partida:
    - k= clave física para direccionar
    - k'= h(k) valor entero entre 0 y M
    - n= número de bits que tiene k' en binario
    - d <= n, los d primeros* dígitos de k' seleccionan el cubo donde está el registro y se llaman pseudollave.
    - b<d<=n, inicialmente el archivo tiene 2^b cubos distintos, como máximo tendrá 2^d. Si son necesarios más, hay que aumentar d.

Hashing dinámico

- Algoritmo
  - Se considera una tabla índice en memoria con 2^d filas
  - En la primera columna de esta tabla (valores de campo clave) se sitúan todas las posibles sucesiones de d dígitos binarios
    - d es la "profundidad global" de la tabla
  - Todos los cubos tienen en principio "profundidad local" igual a b
    - En principio, todas las entradas cuyos b primeros dígitos son iguales apuntan al mismo cubo.
      - Allí se almacenan los registros cuyo valor de k' tiene esos b primeros dígitos.
  - Cuando se llena un cubo se divide en 2, poniendo en uno de ellos los registros con el dígito b+1 de k' a 0 y en otro los que lo tienen igual a 1. La profundidad local de estos cubos aumenta una unidad.

Hashing dinámico

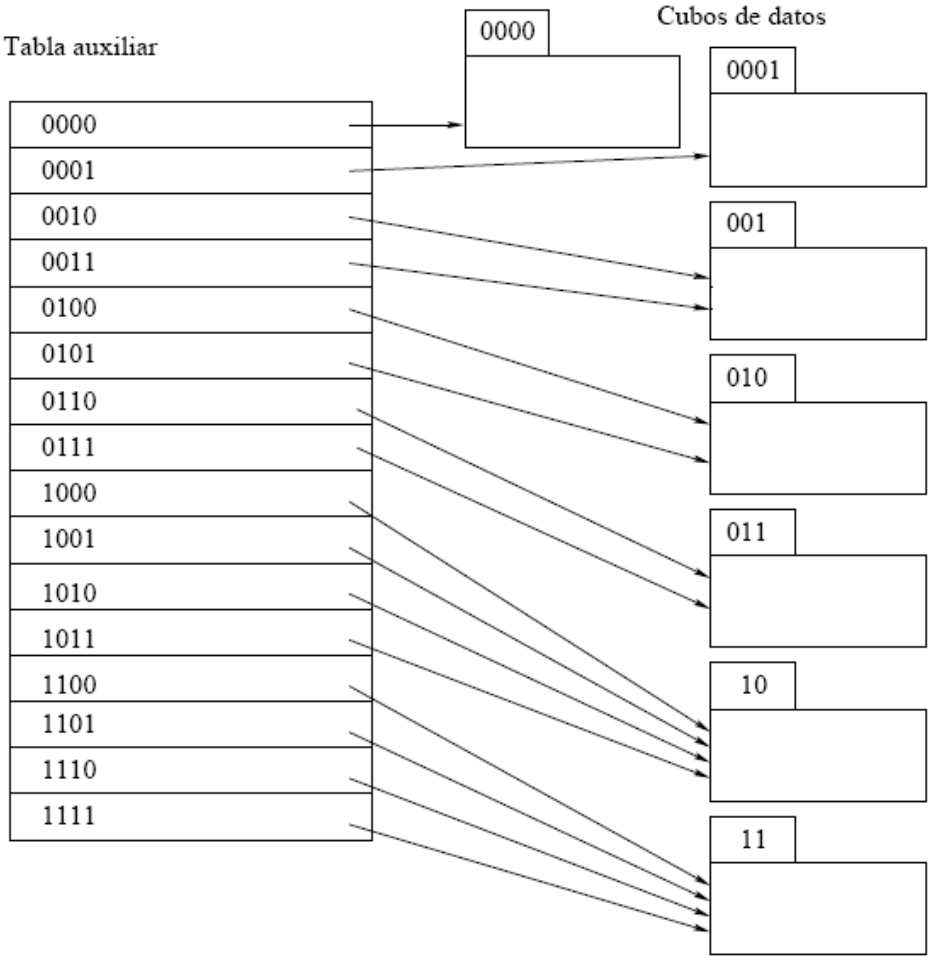

Hashing dinámico

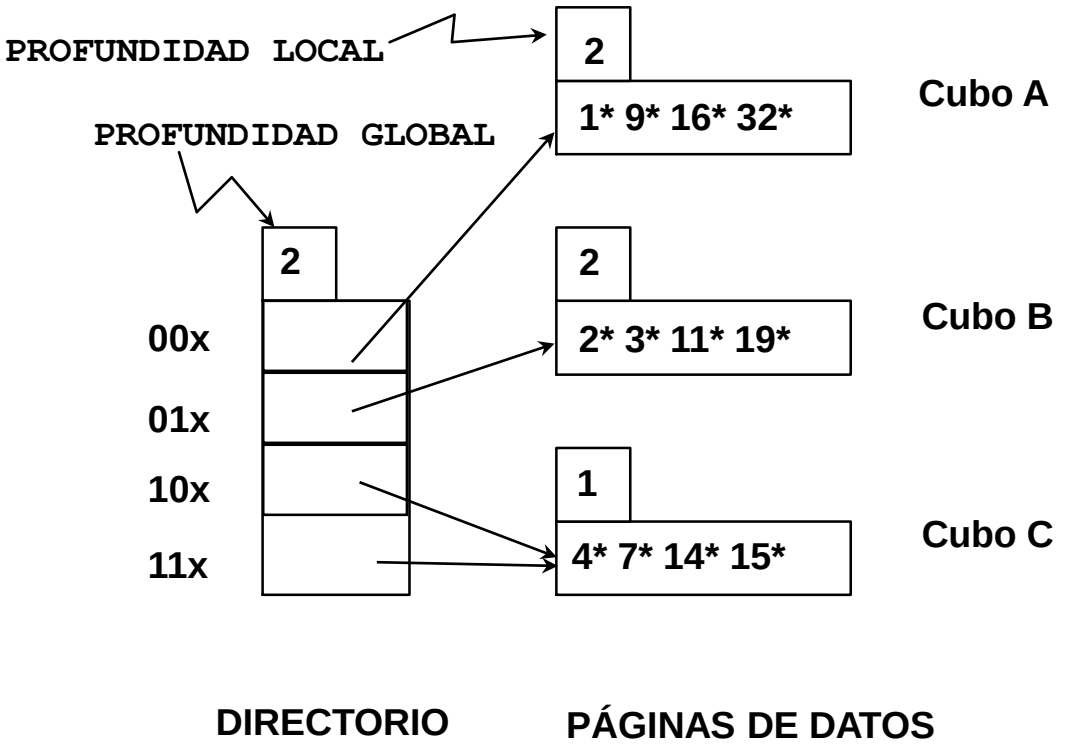

- **Directorio: vector de 4 elementos, h(*k*)= k mod 8**
- **Para encontrar un cubo para *k*, se toman de h(*k*) los últimos bits marcados en *'prof. global '* (2).**
  - Si h(*k*) = 3 = en binario **01**1, cae en el cubo apuntado por **01**.

- Inserción: Si el cubo está lleno, se divide y se re-distribuyen entre los dos cubos.
- Si es necesario, se desdobla el directorio, hasta donde permita la función hash.

Hashing dinámico

Insertamos 17: h(17)=1=**00**1 (Causa desdoblamiento del cubo A y del directorio)

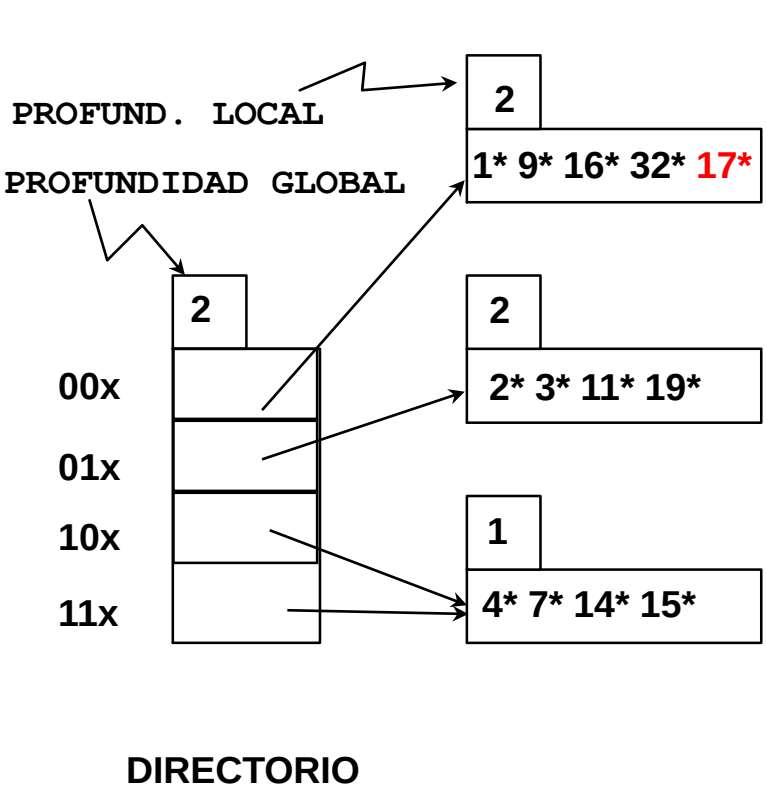

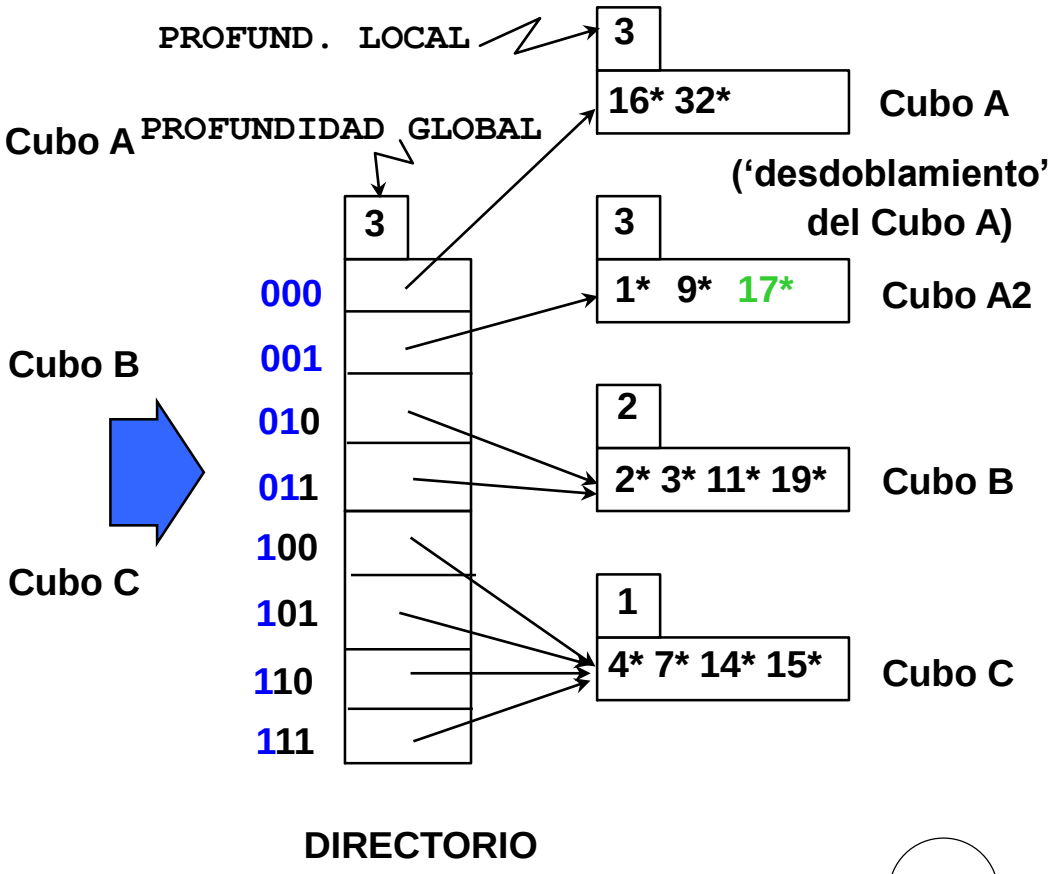

Hashing dinámico

Insertamos 27, h(27)=3 = **01**1 (Solo causa desdoblamiento del Cubo B)

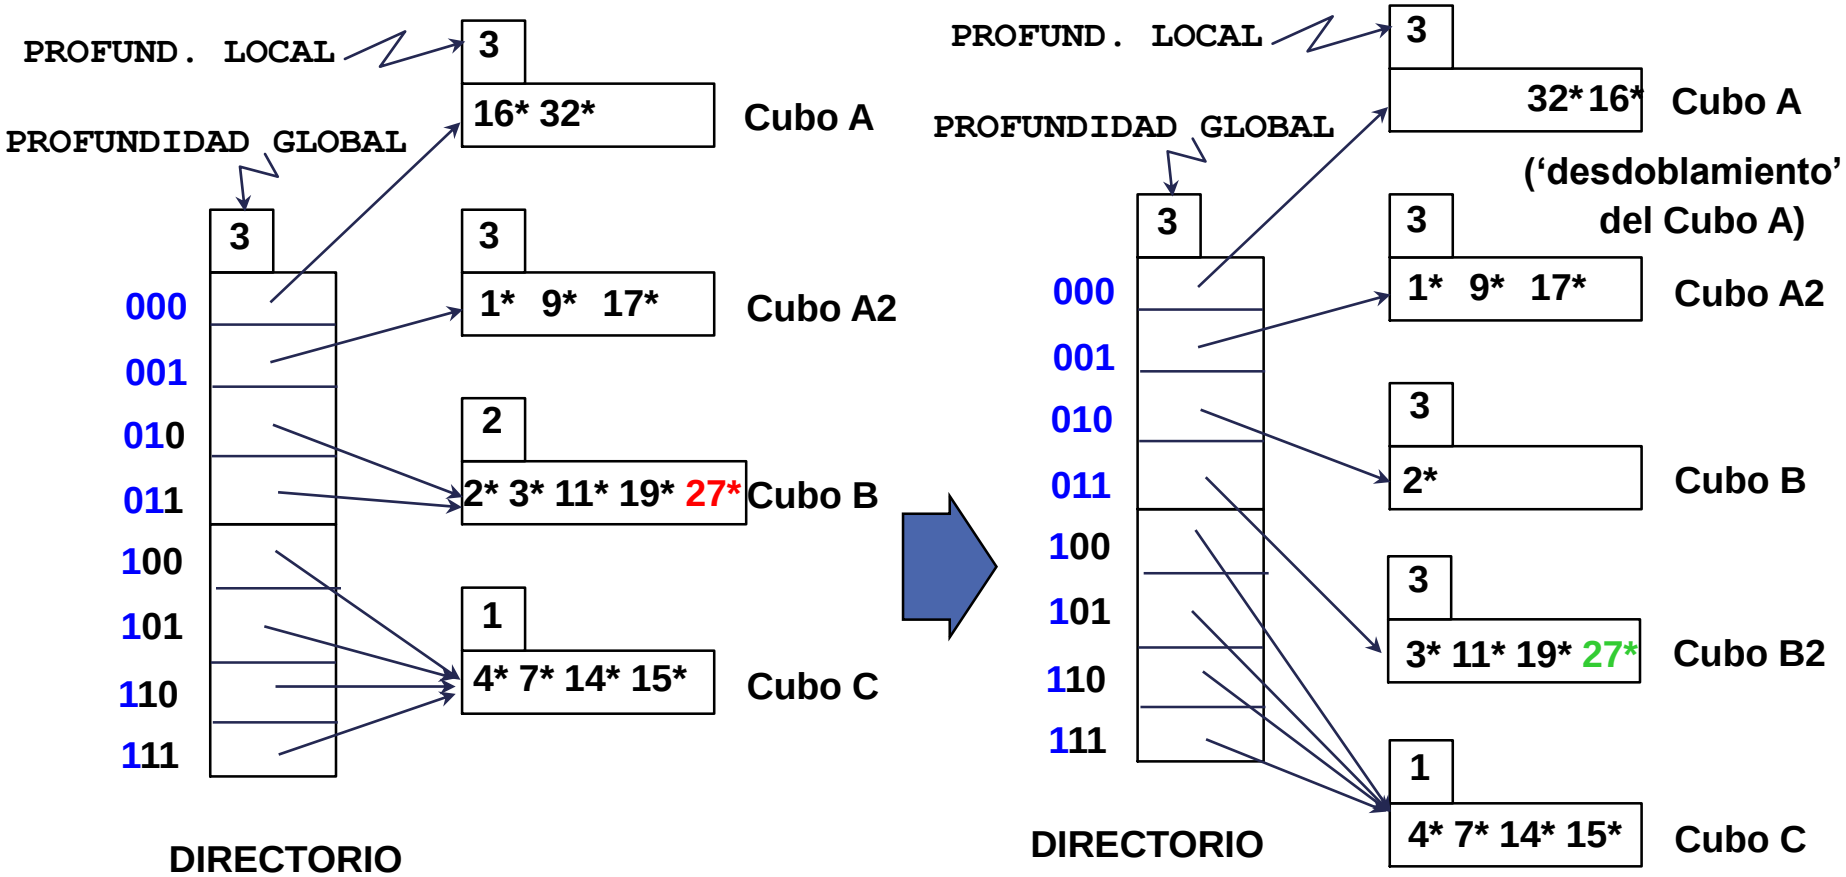

Hashing dinámico

- El hashing dinámico supera algunos problemas clásicos del acceso directo.
- También tiene sus inconvenientes:
  - Utilizar una tabla índice adicional (nuevos accesos a disco si no cabe en memoria).
  - El tamaño de la tabla depende de “d”.

Contenidos

- Acceso directo
- Hashing básico
- Hashing dinámico

Imágenes de portada y cabecera tomadas de https://pixabay.com/